

La actividad de la Semana 6, resuelta y explicada paso a paso

Este documento resuelve la actividad completa de `EIARV011_A6.md`, usando el archivo real `StudentsPerformance.csv` (las notas de 1000 estudiantes). Sigue los mismos pasos que pide el [anexo de la actividad](#), para que puedas usar este documento como guía al armar tu portafolio de verdad.

Paso 1 — Cargar el archivo y mirarlo por primera vez

Imagina que te regalan una caja con 1000 fichas, una por cada estudiante. Cada ficha dice: si es niño o niña, qué tanto estudiaron los papás, si almorzó bien o no tan bien, si hizo un curso antes del examen, y las notas que sacó en matemáticas, lectura y escritura.

Lo primero que hicimos fue **abrir la caja y contar las fichas**: son exactamente 1000, no falta ninguna, y ninguna ficha está en blanco (sin datos). Eso es bueno: significa que podemos trabajar con todas.

Paso 2 — ¿De qué trata esto y qué queremos averiguar?

¿Qué representa este archivo? Son las notas de 1000 estudiantes reales que presentaron un examen, junto con información sobre ellos: si tomaron o no un cursito de preparación antes del examen.

El problema que queremos resolver: algunos estudiantes tomaron ese curso de preparación antes del examen, y otros no. Queremos saber: **¿el curso realmente ayuda a sacar mejor nota en matemáticas, o es pura casualidad?**

Es como preguntarte: si algunos de tus compañeros estudian con un tutor antes de un examen y otros no, ¿de verdad eso hace que les vaya mejor, o simplemente algunos ya eran buenos en matemáticas desde antes?

Nuestra apuesta (las hipótesis):

- **H0 (no pasa nada especial):** el curso de preparación NO cambia la nota de matemáticas.
- **H1 (sí pasa algo):** el curso de preparación SÍ cambia la nota de matemáticas.

Vamos a usar los datos para decidir cuál de las dos apuestas gana.

Paso 3 — ¿Qué cosas vamos a medir y comparar?

De las 8 fichas de información, elegimos dos para nuestra investigación:

- **La nota de matemáticas (math score)** — esto es lo que **queremos explicar**. Es como la altura de una planta: el resultado que observamos.
- **Si tomó o no el curso de preparación (test preparation course)** — esto es lo que **podría estar influyendo**. Es como si regaste o no regaste esa planta.

En palabras de estadística: la nota es la **variable dependiente** (numérica, va de 0 a 100), y el curso es la **variable independiente** (categórica, solo tiene 2 opciones: "sí lo tomó" o "no lo tomó").

Paso 4 — ¿Cuántos estudiantes hay en cada grupo?

De los 1000 estudiantes:

- **642 no tomaron** el curso de preparación.
- **358 sí lo tomaron**.

No quitamos ni agregamos ninguna ficha: usamos las 1000 tal como venían, porque ninguna estaba dañada o incompleta.

Paso 5 — Mirar los números y hacer dibujitos (estadística descriptiva y gráficas)

Antes de sacar conclusiones grandes, primero **resumimos lo que ya vemos** (eso es la estadística descriptiva, como contar tus dulces y sacar el promedio):

- El grupo que **no** tomó el curso promedia **64.08** puntos en matemáticas.
- El grupo que **sí** tomó el curso promedia **69.70** puntos en matemáticas.
- La diferencia es de casi **5.6 puntos**.

También hicimos 3 dibujos para "ver" los datos:

1. **Un histograma** (como una torre de bloques): muestra que la mayoría de los estudiantes sacan notas parecidas al promedio, y pocos sacan notas muy altas o muy bajas — como una campanita.
2. **Un boxplot** (cajas y bigotes): compara los dos grupos uno al lado del otro, y se ve clarito que la caja del grupo "sí tomó el curso" está un poco más arriba.
3. **Un gráfico de puntos extra** (lectura vs. escritura): no era necesario para nuestra pregunta principal, pero mostró que los estudiantes que leen bien también suelen escribir bien — las dos cosas van muy de la mano.

Con solo esto, ¿ya podemos decir que el curso ayuda? Todavía no. Ver una diferencia de 5.6 puntos no basta: necesitamos comprobar si esa diferencia es real o si pudo pasar por pura casualidad (recuerda: 642 y 358 estudiantes son solo una *muestra*, no todos los estudiantes del mundo).

Paso 6 — Revisar si los datos "se comportan normal" (los supuestos)

Antes de usar ciertas herramientas de matemáticas, hay que probar el agua con el dedo antes de meterse a la piscina. Revisamos dos cosas:

¿Los datos forman una campanita (normalidad)? Usamos una prueba llamada Shapiro-Wilk:

- En el grupo que **no** tomó el curso: la campanita **no** salió perfecta (un numerito llamado *p-value* dio 0.0018, que es menor a 0.05).
- En el grupo que **sí** tomó el curso: la campanita **sí** salió razonablemente bien (*p-value* = 0.139, mayor a 0.05).

¿Los dos grupos tienen una variedad parecida (homogeneidad)? Usamos una prueba llamada Levene, y el resultado (*p-value* = 0.4655) dice que **sí**, los dos grupos tienen una variedad parecida.

Como uno de los grupos no formó una campanita perfecta, no podemos confiar del todo en la herramienta "normal" de comparar promedios — hay que usar una un poquito más cuidadosa.

Paso 7 — Elegir la herramienta correcta

Como uno de los grupos no se comportó como campanita, elegimos una herramienta que **no necesita** esa forma perfecta: se llama **Mann-Whitney U**. Es como usar una regla que funciona bien aunque el papel esté un poco arrugado.

Como "chequeo extra" (porque tenemos MUCHOS datos, 1000 en total, y eso ayuda a que hasta la herramienta clásica funcione bien), también usamos la prueba **t de Student**, la herramienta "normal" de toda la vida.

Paso 8 — El resultado y qué significa

Aplicamos las dos herramientas y estos fueron los resultados:

Herramienta	¿Qué tan raro sería este resultado si el curso NO hiciera nada? (p-value)
Mann-Whitney U	0.00000008 (casi cero)
t de Student	0.0000000154 (casi cero)

Ambos números son **muchísimo** más pequeños que 0.05 (nuestra regla del juego). Eso quiere decir: sería casi imposible ver una diferencia tan grande solo por casualidad.

Entonces, ¿qué decidimos? Le creemos a H1: **el curso de preparación SÍ está relacionado con una mejor nota en matemáticas**. Los estudiantes que lo tomaron sacaron, en promedio, 69.70 puntos, contra 64.08 de los que no lo tomaron.

Un cuidado importante: esto no significa que el curso sea "mágico" y le garantice a cualquiera subir la nota. Como no hicimos un experimento (no elegimos al azar quién sí y quién no tomaba el curso), solo podemos decir que están **relacionados**, no que uno *causa* al otro con 100% de seguridad. A lo mejor los estudiantes que se apuntan al curso ya eran más estudiosos desde antes.

Paso 9 — ¿Qué aprendimos?

Sobre revisar los supuestos: aprendimos que antes de usar una herramienta hay que comprobar si los datos se comportan como se espera. En este caso, uno de los grupos no formó una campanita perfecta, así que usamos la herramienta más cuidadosa (Mann-Whitney), y aun así comparamos con la clásica (t de Student) para estar más seguros — y las dos coincidieron.

Las limitaciones de estos datos: no sabemos por qué cada estudiante decidió tomar o no el curso, así que no podemos estar 100% seguros de que el curso *causa* la mejora (podría haber otras razones detrás). Además, hay más estudiantes en el grupo "no tomó el curso" (642) que en el otro (358), lo cual está bien pero no es un empate perfecto.

Qué más se podría investigar: con más información, se podría ver si el curso también ayuda en lectura y escritura, o si otras cosas (como el nivel educativo de los papás) también influyen en la nota, o incluso hacer un experimento de verdad (elegir al azar quién toma el curso) para poder decir con más seguridad que el curso *causa* la mejora.

Resumen de una línea por paso (para armar tu portafolio)

1. **Datos:** 1000 estudiantes, sin datos faltantes.
2. **Pregunta:** ¿el curso de preparación mejora la nota de matemáticas?
3. **Variables:** nota de matemáticas (dependiente) y curso de preparación (independiente).
4. **Grupos:** 642 sin curso, 358 con curso.
5. **Promedios:** 64.08 vs. 69.70 — diferencia de casi 5.6 puntos.
6. **Supuestos:** un grupo no salió "normal"; las varianzas sí son parecidas.
7. **Herramienta elegida:** Mann-Whitney U (con t de Student como chequeo).
8. **Resultado:** p-value casi cero → se rechaza H_0 → sí hay diferencia real.
9. **Conclusión:** el curso de preparación está asociado con mejores notas, pero no podemos asegurar al 100% que sea la única causa.

(Todo el código, las tablas y las gráficas completas de este análisis están en el notebook [EIARV011_A6_Notebook_01.ipynb](#) de esta misma carpeta, usando el archivo `StudentsPerformance.csv`.)