

Taller: Estadística Inferencial — Puente hacia Regresión Lineal (Semanas 7-8)

Fundamentos para IA · NRC 94103

Dataset de referencia: `StudentsPerformance.csv`. Todos los valores de esta clave fueron calculados directamente sobre el archivo real ($\alpha = 0.05$ en todos los casos). Este taller es puramente conceptual (sin código): la idea es que el estudiante razone sobre resultados ya calculados, para consolidar el vocabulario de inferencia que necesitará al construir sus propios modelos de regresión lineal en las Semanas 7 y 8.

Sugerencia de manejo en clase: 8-10 minutos por ejercicio. Los Ejercicios 1-2 son repaso de lo visto en 01 / 02 ; los Ejercicios 3-6 son el puente real hacia regresión — vale la pena dejarles más tiempo y pedir que un par de grupos expliquen en voz alta la interpretación de la pendiente (Ejercicio 4) y del R^2 (Ejercicio 5), porque son los dos conceptos que más se malinterpretan al iniciar regresión lineal.

Ejercicio 1 — Repaso: comparar dos grupos

Situación: `writing score` entre hombres ($n=482$, $\text{media}=63.31$) y mujeres ($n=518$, $\text{media}=72.47$).

Levene: $p=0.934$.

¿Qué evalúa? Si las varianzas (dispersiones) entre dos grupos son iguales

¿Qué significa? Un p-valor de 0.934 es muy alto (> 0.05)

Conclusión: No hay diferencia significativa entre las varianzas de los dos grupos. Asumes que tienen varianzas homogéneas ✓

Prueba t: $t=-9.98$, $p=2.02 \times 10^{-22}$.

¿Qué evalúa? Si las medias (promedios) entre dos grupos son significativamente diferentes

$t = -9.98$: El estadístico t es muy negativo, indicando diferencia importante

$p = 2.02 \times 10^{-22}$: Es un p -valor extremadamente pequeño (prácticamente 0)

Conclusión: Las medias son significativamente diferentes entre grupos ($p < 0.05$). El resultado es altamente significativo ✓✓✓

► Resumen

Los datos muestran que dos grupos tienen varianzas similares pero medias muy diferentes. Esta es la situación ideal para una prueba t clásica. La diferencia observada es estadísticamente robusta (casi imposible de atribuir al azar).

a) Planteamiento de Hipótesis

$H_0: \mu(\text{hombres}) = \mu(\text{mujeres})$. $H_1: \mu(\text{hombres}) \neq \mu(\text{mujeres})$.

► Explicación

H_0 (nula): Las medias de writing score son iguales entre hombres y mujeres.

H_1 (alternativa): Las medias son diferentes (prueba bilateral, por eso $\neq$)

Es el punto de partida: asumes que NO hay diferencia y lo pones a prueba.

b) Verificación del Supuesto

Sí se cumple: $p = 0.934 \geq 0.05$, no se rechaza la homogeneidad de varianzas. Esto respalda usar la prueba t clásica (que asume varianzas iguales, ``equal_var=True``) en lugar de la variante de Welch o una alternativa no paramétrica.

► **Explicación**

El requisito de la prueba t es que ambos grupos tengan varianzas similares.

Levene comprobó: $p = 0.934 \geq 0.05 \rightarrow$ supuesto cumplido ✓

Conclusión: Puedes usar la prueba t clásica (con `equal_var=True`)

Alternativas rechazadas: No necesitas la prueba de Welch (más conservadora) ni pruebas no-paramétricas

c) Decisión Estadística

$p = 2.02 \times 10^{-22} \ll 0.05 \rightarrow$ se rechaza H_0 . "Existe evidencia estadísticamente muy fuerte de que el puntaje de escritura difiere entre hombres y mujeres: las mujeres promedian cerca de 9.2 puntos más."

► **Explicación**

La prueba t arrojó **$p = 2.02 \times 10^{-22}$** (un número minúsculo).

$2.02 \times 10^{-22} \ll 0.05 \rightarrow$ rechazas H_0

En palabras: Hay evidencia estadísticamente muy fuerte de que el puntaje de escritura sí difiere entre géneros

Efecto práctico: Las mujeres obtienen ~9.2 puntos más en promedio ($72.47 - 63.31 \approx 9.16$)

► **Resumen del ejercicio 1**

1. ¿Puedo usar prueba t? Sí (varianzas iguales)
2. ¿Hay diferencia real? Sí (p casi 0)
3. ¿Cuánta? Mujeres superiores por ~9.2 puntos

Ejercicio 2 — Probar si una correlación es significativa (puente a regresión)

Situación: correlación `math score` vs. `reading score` : $r = 0.818$, $p \approx 0$.

- a).** $p \approx 0 \ll 0.05 \rightarrow$ **se rechaza H_0** ($p = 0$). Hay evidencia de que sí existe correlación real en la población, no solo en esta muestra.
- b).** $r = 0.818$ es una correlación **fuerte y positiva** (en general: $|r| \geq 0.7$ se considera fuerte; 0.3-0.7 moderada; < 0.3 débil). Positiva porque ambos puntajes suben o bajan juntos.
- c).** Porque una correlación calculada sobre una muestra pequeña puede parecer "alta" solo por azar. Con apenas 5 estudiantes, es fácil que el azar produzca un r grande sin que exista una relación real en la población — la prueba de hipótesis (con su p -value) es lo que permite distinguir una correlación real de una casualidad de muestra chica. Con 1000 estudiantes, un $r = 0.818$ es mucho más difícil de explicar solo por azar, de ahí el p -value tan cercano a cero.

Ejercicio 3 — Qué SÍ y qué NO te dice el coeficiente de correlación

Situación: $r = 0.955$ entre `reading score` y `writing score`.

- a). Fuerte y positiva** (0.955 está muy cerca de 1).
 - b). No.** Correlación no implica causalidad. Un r alto solo dice que las dos variables tienden a moverse juntas en esta muestra; podría deberse a que ambas dependen de un factor común (por ejemplo, habilidad verbal general, hábitos de estudio, o el mismo tipo de enseñanza recibida), sin que una "cause" directamente a la otra.
 - c) No es correcta.** El coeficiente de correlación (r) mide qué tan fuerte y en qué dirección se mueven dos variables juntas — es adimensional, no tiene "unidades" de puntos. La afirmación de "por cada punto que sube X, Y sube tanto" corresponde a la **pendiente** de la recta de regresión (Ejercicio 4), que es un concepto relacionado pero distinto. Confundir r con la pendiente es uno de los errores más comunes al pasar de correlación a regresión.
-

Ejercicio 4 — Interpretar una recta de regresión lineal simple

Situación: $\text{writing score} = -0.6676 + 0.9935 \times \text{reading score}$.

- a)** La pendiente (0.9935) significa: **por cada punto adicional en reading score, el writing score esperado aumenta, en promedio, 0.9935 puntos** (prácticamente 1 punto). Es la tasa de cambio de la variable que se predice, por unidad de la variable predictora.
- b)** En teoría, el intercepto (-0.6676) sería el writing score esperado cuando reading score = 0. En la práctica, **no tiene sentido interpretarlo literalmente** aquí: el reading score mínimo observado en el dataset es 17, muy lejos de 0, así que ese "punto de partida" de la recta cae fuera del rango de datos reales — el intercepto en este caso es solo un ajuste matemático de la recta, no un valor con significado práctico directo (ver también Ejercicio 6, sobre extrapolación).
- c)** $\text{writing score} = -0.6676 + 0.9935 \times 80 = -0.6676 + 79.48 = \approx \mathbf{78.81 \text{ puntos}}$.
-

Ejercicio 5 — Leer el coeficiente de determinación (R^2)

Situación: $R^2 = 0.911$ para el modelo del Ejercicio 4.

- a)** El modelo explica el **91.1%** de la variación observada en writing score a partir de reading score. Es un R^2 muy alto — el reading score es un predictor muy fuerte de writing score en este dataset.
- b)** El **8.9%** restante corresponde a variación que el modelo no captura: otros factores no incluidos (motivación, calidad de la instrucción, el azar de un día particular del examen, errores de medición, etc.) que también influyen en writing score pero no están representados por reading score.
- c)** Con $R^2 = 0.15$, el modelo explicaría solo el 15% de la variación — sería un predictor **débil**: las predicciones tendrían mucho margen de error y no convendría confiar en ellas para decisiones importantes. Un R^2 bajo no significa que el modelo esté "mal calculado", sino que la variable predictora elegida no explica bien a la variable de interés; haría falta buscar otras variables predictoras o un modelo más complejo.
-

Ejercicio 6 — El riesgo de extrapolar

- Situación:* reading score real va de 17 a 100; predicción del modelo para reading score = 150 da writing score = 148.36.
- a) El problema es que **148.36 está fuera del rango posible** de writing score (0 a 100). Es una señal clara de que algo no funciona: el modelo está "inventando" un resultado imposible.
- b) Porque la recta de regresión se ajustó **solo** con datos donde reading score va de 17 a 100; fuera de ese rango no hay ninguna garantía de que la relación siga siendo lineal (o siquiera de que tenga sentido). **Extrapolar** es aplicar el modelo fuera del rango de los datos observados, asumiendo —sin evidencia— que el mismo patrón se mantiene indefinidamente. Es uno de los errores más comunes al usar regresión lineal para predecir.
- c) Un rango razonable de confianza sería **aproximadamente entre 17 y 100** (el rango real observado en los datos de entrenamiento) —idealmente evitando también los extremos exactos, donde hay menos datos y las predicciones son menos estables.

Cierre: vocabulario que llevas a la Semana 7

Término	En una frase
Correlación (r)	Qué tan fuerte y en qué dirección se mueven juntas dos variables (-1 a 1)
H0: $\rho = 0$	La hipótesis de que no existe correlación real en la población
Pendiente	Cuánto cambia, en promedio, la variable predicha por cada unidad de la predictora
Intercepto	El valor esperado de la variable predicha cuando la predictora es 0 (a veces sin sentido práctico)
R ²	Porcentaje de la variación de la variable predicha que el modelo logra explicar
Extrapolar	Usar el modelo fuera del rango de datos con los que se construyó — riesgoso

Material relacionado

Conceptos base (Semana 6): [01_Estadística_inferencial_conceptos.md](#) y [02_Pruebas_Hipotesis_conceptos.md](#). Versión estudiante de este taller: [Taller_01_Estadística_inferencial.md](#).