

Taller en clase: Estadística Inferencial y Test de Hipótesis (con Python)

Fundamentos para IA · NRC 94103 · Semana 6 Versión docente — clave de respuestas

Dataset de trabajo: `StudentsPerformance.csv` (1000 registros). Todo el código de esta clave fue ejecutado directamente sobre el archivo real, con `pandas` / `scipy.stats` ($\alpha = 0.05$ en todos los casos). Cada ejercicio corresponde uno a uno con el mismo número en [01_Estadística_inferencial_conceptos.md](#), que trae la versión sin código de estas mismas preguntas.

Configuración inicial:

```
import pandas as pd
import numpy as np
from scipy import stats

df = pd.read_csv("StudentsPerformance.csv")
```

Ejercicio 1 — Estadística descriptiva vs. inferencial

```
none = df.loc[df["test preparation course"] == "none", "math score"]
completado = df.loc[df["test preparation course"] == "completed", "math score"]

print(f"n sin curso = {len(none)}, media = {none.mean():.2f}")
print(f"n con curso = {len(completado)}, media = {completado.mean():.2f}")
```

```
n sin curso = 642, media = 64.08
n con curso = 358, media = 69.70
```

- a) `len()` cuenta y `.mean()` promedia lo que ya está en los datos: son **estadística descriptiva** — resumen puro de la muestra, sin generalizar nada.
- b) Esa conclusión es **inferencial**: extiende el patrón observado en 1000 estudiantes hacia *todos* los estudiantes que presentan el examen. Hace falta algo más que los dos promedios porque la diferencia ($69.70 - 64.08 \approx 5.6$ puntos) podría deberse al azar de qué 1000 estudiantes en particular quedaron en la muestra; se necesita una prueba de hipótesis (Ejercicio 5) para decidir si esa diferencia es real o explicable por puro azar muestral.
-

Ejercicio 2 — Población y muestra

```
conteo = df["parental level of education"].value_counts()
print(conteo)

promedios = df.groupby("parental level of education")["math score"].mean().round(2)
print(promedios)
```

some college	226
associate's degree	222
high school	196
some high school	179
bachelor's degree	118
master's degree	59

- a)** Grupo más pequeño: `master's degree` (59 estudiantes). Grupo más grande: `some college` (226).
- b) Población:** todos los estudiantes del mundo que presentan este tipo de examen. **Muestra:** los 1000 estudiantes del *dataset*.
- c)** Con solo 59 estudiantes, cada dato individual "pesa" más en el promedio: un solo estudiante con nota muy alta o muy baja desplaza más el resultado que en un grupo de 226, donde ese mismo caso atípico se diluye entre muchos más datos. Por eso el promedio del grupo pequeño es una estimación menos estable del verdadero promedio poblacional de ese grupo.
-

Ejercicio 3 — Variables dependiente e independiente

```
print(df[["lunch", "writing score", "reading score", "gender", "math score"]].dtypes)

correlacion = df["reading score"].corr(df["writing score"])
print(f"Correlación reading vs. writing: {correlacion:.3f}")
```

```
lunch          str
writing score  int64
reading score  int64
gender         str
math score     int64
Correlación reading vs. writing: 0.955
```

- a)** Dependiente: `writing score` . Independiente: `lunch` .
- b)** Ambas son numéricas y se busca una **correlación** ($r = 0.955$, muy fuerte), no un efecto de una sobre otra: no hay una dependiente/independiente fija.
- c)** Dependiente: `math score` . Independiente: `gender` .

Ejercicio 4 — Plantear H0 y H1 con datos reales

```
standard = df.loc[df["lunch"] == "standard", "writing score"]
reducido = df.loc[df["lunch"] == "free/reduced", "writing score"]

print(f"\n standard = {len(standard)}, media = {standard.mean():.2f}")
print(f"\n free/reduced = {len(reducido)}, media = {reducido.mean():.2f}")
```

```
n standard = 645, media = 70.82
n free/reduced = 355, media = 63.02
```

H0: $\mu(\text{standard}) = \mu(\text{free/reduced})$ — **H1:** $\mu(\text{standard}) \neq \mu(\text{free/reduced})$. Los promedios ya calculados (70.82 vs. 63.02) sugieren una diferencia, pero recién se confirma como "real" (no azar) al aplicar la prueba de hipótesis correspondiente.

Ejercicio 5 — Calcular e interpretar un p-value

```
resultado = stats.mannwhitneyu(none, completado, alternative="two-sided")
print(f"Mann-Whitney U -> estadístico={resultado.statistic:.1f}, p-value={resultado.pvalue:.4g}")
```

```
Mann-Whitney U -> estadístico=91424.0, p-value=8.015e-08
```

a) Chiquito — muchísimo menor que $\alpha = 0.05$.

b) Se **rechaza H0**.

c) "Hay evidencia estadísticamente muy fuerte de que el puntaje de matemáticas difiere entre quienes tomaron el curso de preparación y quienes no (69.70 vs. 64.08 en promedio); sería casi imposible ver una diferencia así de grande por puro azar si el curso no tuviera ningún efecto."

Ejercicio 6 — Errores tipo I y tipo II: el efecto del tamaño de muestra

```
muestra_chica = df.sample(n=50, random_state=42)

n_chico = muestra_chica.loc[muestra_chica["test preparation course"] == "none", "math score"]
c_chico = muestra_chica.loc[muestra_chica["test preparation course"] == "completed", "math score"]

print(f"n sin curso = {len(n_chico)}, n con curso = {len(c_chico)}")
resultado_chico = stats.mannwhitneyu(n_chico, c_chico, alternative="two-sided")
print(f"p-value con n=50 -> {resultado_chico.pvalue:.4g}")
```

```
n sin curso = 30, n con curso = 20
p-value con n=50 -> 0.6274
```

a) Con $n = 1000$ el p-value era 8.02×10^{-8} (se rechazaba H_0); con esta submuestra de solo 50 estudiantes el p-value sube a **0.627**, muy por encima de 0.05 — **ya no se rechazaría H_0** con esta muestra chica.

b) Sería un **error tipo II**: no detectar (con la muestra de 50) un efecto que sí existe en la población — como lo confirma la muestra completa de 1000.

c) A menor tamaño de muestra, menor **poder estadístico**: la prueba tiene menos capacidad de detectar un efecto real, aunque ese efecto exista. Este mismo curso de preparación, con el mismo efecto real de fondo, "desaparece" estadísticamente solo por haber usado una muestra 20 veces más chica — la evidencia disponible ya no alcanza para distinguir el patrón real del ruido del azar.

(Nota pedagógica: el resultado exacto de este bloque depende de `random_state=42`; si se cambia la semilla, el p-value cambiará, pero la lección — que muestras chicas detectan peor los efectos reales — se mantiene.)

Ejercicio 7 — Validar los supuestos (normalidad y homogeneidad)

```
shapiro_none = stats.shapiro(none)
shapiro_completado = stats.shapiro(completado)
levene = stats.levene(none, completado)

print(f"Shapiro-Wilk 'none'      -> p-value={shapiro_none.pvalue:.4g}")
print(f"Shapiro-Wilk 'completed' -> p-value={shapiro_completado.pvalue:.4g}")
print(f"Levene -> p-value={levene.pvalue:.4g}")
```

```
Shapiro-Wilk 'none'      -> p-value=0.001754
Shapiro-Wilk 'completed' -> p-value=0.1393
Levene -> p-value=0.4655
```

- a)** No de forma conjunta: `none` tiene $p = 0.0018$ (< 0.05 , se rechaza la normalidad); `completed` tiene $p = 0.139$ (≥ 0.05 , no se rechaza).
- b)** Sí: Levene da $p = 0.4655$ (≥ 0.05) → se cumple la homogeneidad de varianzas.
- c)** Sí fue buena decisión: al no cumplirse la normalidad de forma conjunta, Mann-Whitney U (no paramétrica) es la elección más segura como prueba principal. Dado que las varianzas sí son homogéneas y la muestra es grande, también sería válido reportar la prueba t de Student como verificación de robustez (ambas coinciden en el resultado, como se vio en el Ejercicio 5).
-

Ejercicio 8 — Elegir la prueba con más de 2 grupos

```
grupos = [g["math score"].values for _, g in df.groupby("race/ethnicity")]

anova = stats.f_oneway(*grupos)
kruskal = stats.kruskal(*grupos)

print(f"ANOVA -> statistic={anova.statistic:.2f}, p-value={anova.pvalue:.4g}")
print(f"Kruskal-Wallis -> statistic={kruskal.statistic:.2f}, p-value={kruskal.pvalue:.4g}")
```

```
ANOVA -> statistic=14.59, p-value=1.373e-11
Kruskal-Wallis -> statistic=57.08, p-value=1.191e-11
```

- a)** Se comparan **5 grupos** (más de 2). Herramienta paramétrica: **ANOVA de un factor**. Alternativa no paramétrica: **Kruskal-Wallis**.
- b)** Ambas dan $p\text{-value} \ll 0.05 \rightarrow$ **se rechaza H_0** : al menos un grupo étnico tiene una media de `math score` distinta a los demás.
- c)** Habría que aplicar una **prueba post-hoc** (por ejemplo, la prueba de Tukey HSD para ANOVA, o comparaciones por pares con corrección de Bonferroni para Kruskal-Wallis), que compara los grupos de dos en dos para identificar cuáles pares específicos son estadísticamente distintos entre sí — ANOVA/Kruskal-Wallis solo dicen que *existe* alguna diferencia, no *entre cuáles* grupos.
-

Material relacionado

Conceptos sin código: [01_Estadística_inferencial_conceptos.md](#). Versión estudiante de este taller:

[Taller_01_Estadística_inferencial_conceptos.md](#). Presentación: [01_Estadística_inferencial_conceptos.pptx](#).