

Taller: Estadística Inferencial y Test de Hipótesis (con Python)

Fundamentos para IA · NRC 94103 · Semana 6 Versión docente — solución completa, paso a paso, con código

Este *notebook* resuelve en detalle los 8 ejercicios de `Taller_02_Estadistica_inferencial_conceptos_profesor.md` (que a su vez desarrollan, con código, los ejercicios conceptuales de `01_Estadistica_inferencial_conceptos.md`). Para cada ejercicio se muestra: la **fórmula**, el **cálculo manual** paso a paso, la **verificación** con `scipy`, y la **interpretación**.

Configuración inicial

```
In [1]: import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
from scipy import stats

sns.set_theme(style="whitegrid")
pd.set_option("display.max_columns", None)

df = pd.read_csv("StudentsPerformance.csv")
alpha = 0.05
print(f"Dataset: {df.shape[0]} estudiantes, {df.shape[1]} columnas.")
df.head()
```

Dataset: 1000 estudiantes, 8 columnas.

Out[1]:	gender	race/ethnicity	parental level of education	lunch	test preparation course	math score	reading score	writing score
0	female	group B	bachelor's degree	standard	none	72	72	74
1	female	group C	some college	standard	completed	69	90	88
2	female	group B	master's degree	standard	none	90	95	93
3	male	group A	associate's degree	free/reduced	none	47	57	44
4	male	group C	some college	standard	none	76	78	75

Ejercicio 1 — Estadística descriptiva vs. inferencial

Situación: ¿el curso de preparación (`test preparation course`) se asocia con el puntaje de matemáticas?

```
In [2]: none = df.loc[df["test preparation course"] == "none", "math score"]
completado = df.loc[df["test preparation course"] == "completed", "math score"]

print(f"n sin curso = {len(none)}, media = {none.mean():.2f}")
print(f"n con curso = {len(completado)}, media = {completado.mean():.2f}")
```

n sin curso = 642, media = 64.08

n con curso = 358, media = 69.70

a) `len()` y `.mean()` son **estadística descriptiva** — resumen puro de la muestra, sin generalizar.

b) Decir "el curso mejora el puntaje de *TODO*s los estudiantes que presentan el examen" es **inferencial**: extiende el patrón de 1000 estudiantes hacia toda la población. La diferencia observada ($69.70 - 64.08 \approx 5.6$ puntos) podría deberse al azar de la muestra — hace falta una prueba de hipótesis (Ejercicio 5) para saberlo con evidencia, no solo con los dos promedios.

Ejercicio 2 — Población y muestra

Situación: tamaño de los 6 grupos de `parental level of education`.

```
In [3]: conteo = df["parental level of education"].value_counts()
print(conteo)

promedios = df.groupby("parental level of education")["math score"].agg(["count", "mean", "std"]).round(2)
promedios["error_estandar"] = (promedios["std"] / np.sqrt(promedios["count"])).round(3)
promedios.sort_values("count")
```

```
parental level of education
some college          226
associate's degree    222
high school           196
some high school      179
bachelor's degree     118
master's degree        59
Name: count, dtype: int64
```

```
Out[3]:
```

	count	mean	std	error_estandar
parental level of education				
master's degree	59	69.75	15.15	1.972
bachelor's degree	118	69.39	14.94	1.375
some high school	179	63.50	15.93	1.191
high school	196	62.14	14.54	1.039
associate's degree	222	67.88	15.11	1.014
some college	226	67.13	14.31	0.952

a) Grupo más pequeño: `master's degree` (59). Grupo más grande: `some college` (226).

b) **Población:** todos los estudiantes del mundo que presentan este examen. **Muestra:** los 1000 del *dataset*.

c) Con menos datos, cada dato "pesa" más — y esto se puede **cuantificar**: el error estándar de una media es $SE = \frac{s}{\sqrt{n}}$. La tabla de arriba muestra que `master's degree` (n=59) tiene un error estándar bastante más grande que `some college` (n=226): la estimación del

promedio es menos precisa cuanto más chico es el grupo, porque $\sqrt{n}$ crece más lento que n pero divide directamente la incertidumbre.

Ejercicio 3 — Variables dependiente e independiente

```
In [4]: print(df[["lunch", "writing score", "reading score", "gender", "math score"]].dtypes)

correlacion = df["reading score"].corr(df["writing score"])
print(f"\nCorrelación reading vs. writing: {correlacion:.3f}")
```

```
lunch          str
writing score  int64
reading score  int64
gender         str
math score     int64
dtype: object
```

Correlación reading vs. writing: 0.955

- a) ¿lunch se relaciona con writing score? → Dependiente: writing score . Independiente: lunch .
- b) ¿reading score se relaciona con writing score? → ambas numéricas, se busca una **correlación** ($r=0.955$), no hay dependiente/independiente fija.
- c) ¿gender se relaciona con math score? → Dependiente: math score . Independiente: gender .
-

Ejercicio 4 — Plantear H0 y H1 con datos reales

Situación: ¿el tipo de almuerzo (lunch) se relaciona con writing score ?

- H0: $\mu(\text{standard}) = \mu(\text{free/reduced})$
- H1: $\mu(\text{standard}) \neq \mu(\text{free/reduced})$

```
In [5]: standard = df.loc[df["lunch"] == "standard", "writing score"]
        reducido = df.loc[df["lunch"] == "free/reduced", "writing score"]

        print(f"n standard = {len(standard)}, media = {standard.mean():.2f}")
        print(f"n free/reduced = {len(reducido)}, media = {reducido.mean():.2f}")
```

```
n standard = 645, media = 70.82
n free/reduced = 355, media = 63.02
```

Los promedios (70.82 vs. 63.02) sugieren una diferencia, pero solo se confirma como "real" (y no azar) al aplicar una prueba de hipótesis formal — que es justo lo que se hace en los Ejercicios 5-7 con la otra variable (`test preparation course`); el mismo procedimiento aplica igual aquí.

Ejercicio 5 — Calcular e interpretar un p-value (Mann-Whitney U, paso a paso)

Situación: ¿el curso de preparación se relaciona con `math score` ?

La lógica de Mann-Whitney U

En vez de comparar promedios, se **ordenan** los 1000 estudiantes juntos (de menor a mayor puntaje) y se compara la suma de los **rangos** (puestos en el orden) que le tocaron a cada grupo.

$$U_1 = R_1 - \frac{n_1(n_1 + 1)}{2} \quad U = \min(U_1, U_2)$$

$$\mu_U = \frac{n_1 n_2}{2} \quad \sigma_U = \sqrt{\frac{n_1 n_2 (n_1 + n_2 + 1)}{12}}$$

$$z = \frac{U - \mu_U}{\sigma_U}$$

```
In [6]: n1, n2 = len(none), len(completado)
        todos = np.concatenate([none.values, completado.values])
```

```

rangos = stats.rankdata(todos)

R1 = rangos[:n1].sum()
U1 = R1 - n1 * (n1 + 1) / 2
U2 = n1 * n2 - U1
U_manual = min(U1, U2)

mu_U = n1 * n2 / 2
sigma_U = np.sqrt(n1 * n2 * (n1 + n2 + 1) / 12)
z = (U_manual - mu_U) / sigma_U
p_manual = 2 * stats.norm.sf(abs(z))

print(f"Suma de rangos (sin curso), R1 = {R1:,.1f}")
print(f"U1={U1:,.1f} U2={U2:,.1f} U={U_manual:,.1f}")
print(f"mu_U={mu_U:,.1f} sigma_U={sigma_U:,.1f} z={z:.3f}")
print(f"p-value aproximado (normal, sin corrección de empates) = {p_manual:.4g}")

resultado = stats.mannwhitneyu(none, completado, alternative="two-sided")
print(f"\nMann-Whitney U (scipy, con corrección de empates) -> "
      f"estadístico={resultado.statistic:.1f}, p-value={resultado.pvalue:.4g}")

```

Suma de rangos (sin curso), R1 = 297,827.0
 U1=91,424.0 U2=138,412.0 U=91,424.0
 mu_U=114,918.0 sigma_U=4,378.6 z=-5.366
 p-value aproximado (normal, sin corrección de empates) = 8.066e-08

Mann-Whitney U (scipy, con corrección de empates) -> estadístico=91424.0, p-value=8.015e-08

Nota: el p-value manual (aproximación normal) y el de `scipy` (que aplica una corrección por los muchos empates de notas enteras) son casi idénticos — la diferencia mínima confirma que la aproximación manual es correcta.

a) $p \approx 8 \times 10^{-8}$ es **chiquito** ($\ll 0.05$). **b)** Se **rechaza H0**. **c)** "Hay evidencia estadísticamente muy fuerte de que el puntaje de matemáticas difiere entre quienes tomaron el curso y quienes no (69.70 vs. 64.08); sería casi imposible ver una diferencia así por puro azar si el curso no tuviera ningún efecto."

Ejercicio 6 — Errores tipo I y tipo II: el efecto del tamaño de muestra

Se repite la misma prueba del Ejercicio 5, pero con una submuestra aleatoria de solo 50 estudiantes.


```
In [7]: muestra_chica = df.sample(n=50, random_state=42)

n_chico = muestra_chica.loc[muestra_chica["test preparation course"] == "none", "math score"]
c_chico = muestra_chica.loc[muestra_chica["test preparation course"] == "completed", "math score"]

print(f"n sin curso = {len(n_chico)}, n con curso = {len(c_chico)}")
resultado_chico = stats.mannwhitneyu(n_chico, c_chico, alternative="two-sided")
print(f"p-value con n=50 -> {resultado_chico.pvalue:.4g}")
print(f"p-value con n=1000 (Ejercicio 5) -> {resultado.pvalue:.4g}")

n sin curso = 30, n con curso = 20
p-value con n=50 -> 0.6274
p-value con n=1000 (Ejercicio 5) -> 8.015e-08
```

```
In [8]: fig, ax = plt.subplots(figsize=(6, 4))
tamanos = [50, 1000]
pvalues = [resultado_chico.pvalue, resultado.pvalue]
ax.bar([str(t) for t in tamanos], pvalues, color=["#E07A5F", "#3D5A80"])
ax.axhline(0.05, color="red", linestyle="--", label="α = 0.05")
ax.set_yscale("log")
ax.set_ylabel("p-value (escala log)")
ax.set_xlabel("Tamaño de muestra")
ax.set_title("El mismo efecto real: p-value según el tamaño de muestra")
ax.legend()
plt.tight_layout()
plt.show()
```



- a) Con $n=1000$, $p=8.02 \times 10^{-8}$ (se rechazaba H_0); con $n=50$, p sube a **0.627** — ya no se rechazaría H_0 .
- b) Sería un **error tipo II**: no detectar, con la muestra chica, un efecto que sí existe en la población (como confirma la muestra completa).
- c) A menor tamaño de muestra, menor **poder estadístico** — la prueba pierde capacidad de distinguir un efecto real del ruido del azar, aunque el efecto de fondo sea exactamente el mismo en los dos casos.

Ejercicio 7 — Validar los supuestos (normalidad y homogeneidad)

Levene, paso a paso (recordatorio de la fórmula)

$$W = \frac{N - k}{k - 1} \cdot \frac{\sum_i n_i (\bar{Z}_{i\cdot} - \bar{Z}_{..})^2}{\sum_i \sum_j (Z_{ij} - \bar{Z}_{i\cdot})^2} \quad Z_{ij} = |X_{ij} - \tilde{X}_i|$$

```
In [9]: shapiro_none = stats.shapiro(none)
shapiro_completado = stats.shapiro(completado)

print(f"Shapiro-Wilk 'none'      -> statistic={shapiro_none.statistic:.4f}, p-value={shapiro_none.pvalue:.4g}")
print(f"Shapiro-Wilk 'completed' -> statistic={shapiro_completado.statistic:.4f}, p-value={shapiro_completado.pvalue:.4g}")

def levene_manual(g1, g2):
    Ns = [len(g1), len(g2)]
    N, k = sum(Ns), 2
    centros = [np.median(g1), np.median(g2)]
    Z = [np.abs(np.asarray(g) - c) for g, c in zip([g1, g2], centros)]
    Zbar_i = [z.mean() for z in Z]
    Zbar = np.concatenate(Z).mean()
    numerador = (N - k) * sum(n * (zi - Zbar) ** 2 for n, zi in zip(Ns, Zbar_i))
    denominador = (k - 1) * sum(((z - zi) ** 2).sum() for z, zi in zip(Z, Zbar_i))
    W = numerador / denominador
    p = stats.f.sf(W, k - 1, N - k)
    return W, p

W_lev, p_lev_manual = levene_manual(none, completado)
print(f"\nLevene manual -> W={W_lev:.6f}, p-value={p_lev_manual:.6f}")
levene_scipy = stats.levene(none, completado)
print(f"Levene (scipy) -> W={levene_scipy.statistic:.6f}, p-value={levene_scipy.pvalue:.6f}")
```

Shapiro-Wilk 'none' -> statistic=0.9921, p-value=0.001754

Shapiro-Wilk 'completed' -> statistic=0.9937, p-value=0.1393

Levene manual -> W=0.533017, p-value=0.465513

Levene (scipy) -> W=0.533017, p-value=0.465513

a) No de forma conjunta: `none` $p=0.0018$ (<0.05 , se rechaza normalidad); `completed` $p=0.139$ (≥ 0.05 , no se rechaza).

b) Sí: Levene da $p=0.4655$ (≥ 0.05) → se cumple la homogeneidad de varianzas.

c) Sí fue buena decisión usar Mann-Whitney U como prueba principal (la normalidad falla en un grupo). Con varianzas homogéneas y muestra grande, también es válida la prueba t como verificación de robustez — ambas coincidieron en el Ejercicio 5.

Ejercicio 8 — Elegir la prueba con más de 2 grupos (ANOVA y Kruskal-Wallis, paso a paso)

Situación: `race/ethnicity` tiene 5 grupos. ¿Difiere `math score` entre ellos?

ANOVA de un factor

La idea: comparar cuánto varían las medias **entre** grupos (¿tan distintas que no parece azar?) contra cuánto varían los datos **dentro** de cada grupo (el "ruido" normal).

$$F = \frac{MS_B}{MS_W} = \frac{SS_B/(k-1)}{SS_W/(N-k)}$$

$$SS_B = \sum_i n_i (\bar{x}_i - \bar{x})^2 \quad SS_W = \sum_i \sum_j (x_{ij} - \bar{x}_i)^2$$

```
In [10]: grupos = [g["math score"].values for _, g in df.groupby("race/ethnicity")]
etiquetas = df["race/ethnicity"].unique()
k = len(grupos)
N = sum(len(g) for g in grupos)
grand_mean = np.concatenate(grupos).mean()

SSB = sum(len(g) * (g.mean() - grand_mean) ** 2 for g in grupos)
SSW = sum(((g - g.mean()) ** 2).sum() for g in grupos)
dfB, dfW = k - 1, N - k
MSB, MSW = SSB / dfB, SSW / dfW
F_manual = MSB / MSW
p_anova_manual = stats.f.sf(F_manual, dfB, dfW)

print(f"k={k} grupos, N={N} estudiantes")
print(f"SSB={SSB:,.2f} SSW={SSW:,.2f}")
print(f"dfB={dfB} dfW={dfW}")
print(f"MSB={MSB:,.2f} MSW={MSW:,.2f}")
```

```
print(f"F manual -> F={F_manual:.4f}, p-value={p_anova_manual:.4g}")

anova_scipy = stats.f_oneway(*grupos)
print(f"ANOVA (scipy) -> F={anova_scipy.statistic:.4f}, p-value={anova_scipy.pvalue:.4g}")
```

k=5 grupos, N=1000 estudiantes
SSB=12,728.82 SSW=216,960.26
dfB=4 dfW=995
MSB=3,182.20 MSW=218.05
F manual -> F=14.5939, p-value=1.373e-11
ANOVA (scipy) -> F=14.5939, p-value=1.373e-11

Kruskal-Wallis (la versión no paramétrica, basada en rangos)

$$H = \frac{12}{N(N+1)} \sum_i \frac{R_i^2}{n_i} - 3(N+1)$$

donde R_i es la suma de rangos del grupo i (ordenando todos los datos juntos, igual que en Mann-Whitney). H se compara contra una distribución χ^2 con $k - 1$ grados de libertad.

```
In [11]: todos_g = np.concatenate(grupos)
rangos_g = stats.rankdata(todos_g)

idx, H_suma = 0, 0.0
for g in grupos:
    ni = len(g)
    Ri = rangos_g[idx:idx + ni].sum()
    H_suma += Ri ** 2 / ni
    idx += ni

H_manual = (12 / (N * (N + 1))) * H_suma - 3 * (N + 1)
p_kw_manual = stats.chi2.sf(H_manual, k - 1)


print(f"H manual -> H={H_manual:.4f}, p-value={p_kw_manual:.4g}")

kruskal_scipy = stats.kruskal(*grupos)
print(f"Kruskal-Wallis (scipy) -> H={kruskal_scipy.statistic:.4f}, p-value={kruskal_scipy.pvalue:.4g}")
```

H manual -> $H=57.0525$, $p\text{-value}=1.206e-11$

Kruskal-Wallis (scipy) -> $H=57.0793$, $p\text{-value}=1.191e-11$

```
In [12]: fig, ax = plt.subplots(figsize=(7, 4))
orden = sorted(df["race/ethnicity"].unique())
sns.boxplot(data=df, x="race/ethnicity", y="math score", order=orden,
            hue="race/ethnicity", palette="Set2", legend=False, ax=ax)
ax.set_title("math score por grupo étnico (5 grupos)")
plt.tight_layout()
plt.show()
```



a) Se comparan **5 grupos** (más de 2). Paramétrica: **ANOVA de un factor**. No paramétrica: **Kruskal-Wallis**.

b) Ambas dan $p\text{-value} \ll 0.05 \rightarrow$ **se rechaza H_0** : al menos un grupo étnico tiene una media de `math score` distinta a los demás.

c) Para saber **cuáles** grupos específicos difieren (no solo que "alguno" difiere) haría falta una **prueba post-hoc** — por ejemplo Tukey HSD (para ANOVA) o comparaciones por pares con corrección de Bonferroni (para Kruskal-Wallis).

Resumen de fórmulas usadas en este taller

Prueba	Compara	Fórmula clave
Mann-Whitney U	2 grupos, sin asumir normalidad	$U = \min(U_1, U_2)$, basado en rangos
Prueba t	2 grupos, con normalidad/homogeneidad	$t = (\bar{x}_1 - \bar{x}_2)/SE$
Levene	Homogeneidad de varianzas	W sobre $Z_{ij} = X_{ij} - \tilde{X}_i $
Shapiro-Wilk	Normalidad de un grupo	Correlación entre datos ordenados y su forma normal esperada
ANOVA	3+ grupos, con normalidad/homogeneidad	$F = MS_B/MS_W$
Kruskal-Wallis	3+ grupos, sin asumir normalidad	H basado en rangos, $\sim \chi^2_{k-1}$

Material relacionado: versión conceptual sin código — `01_Estadistica_inferencial_conceptos.md` . Clave de respuestas en Markdown de este mismo taller: `Taller_02_Estadistica_inferencial_conceptos_profesor.md` .