

Taller en clase: Prueba de Hipótesis (con Python)

Fundamentos para IA · NRC 94103 · Semana 6 Versión docente — clave de respuestas

Dataset de trabajo: `StudentsPerformance.csv` (1000 registros). Todo el código de esta clave fue ejecutado directamente sobre el archivo real, con `pandas / scipy.stats` ($\alpha = 0.05$ en todos los casos). Cada ejercicio corresponde uno a uno con el mismo número en [02_Pruebas_Hipotesis_conceptos.md](#), que trae la versión sin código de estas mismas preguntas.

Configuración inicial:

```
import pandas as pd
import numpy as np
from scipy import stats

df = pd.read_csv("StudentsPerformance.csv")
alpha = 0.05
```

Ejercicio 1 — ¿Es candidata para una prueba de hipótesis?

```
print(df["lunch"].value_counts())
print(df.groupby("gender")["math score"].mean().round(2))

correlacion = df["reading score"].corr(df["writing score"])
print(f"Correlación reading vs. writing: {correlacion:.3f}")
```

```
lunch
standard      645
free/reduced  355
```

```
gender
female      63.63
male       68.73
```

```
Correlación reading vs. writing: 0.955
```

a) Situación A (math score por gender): **sí es candidata**. Hay una comparación entre grupos (68.73 vs. 63.63) y una pregunta de generalización hacia la población.

Situación B (conteo de `lunch`): **no es candidata**. `value_counts()` es pura estadística descriptiva — no hay ninguna comparación con incertidumbre que resolver.

Situación C (correlación reading/writing = 0.955): **sí es candidata**. Aunque es una relación entre dos variables numéricas (no una diferencia entre grupos), sigue siendo el mismo salto de "lo que veo en la muestra" a "lo que sería cierto en la población".

Ejercicio 2 — H0 y H1 con más de dos grupos

```
grupos = [g["math score"].values for _, g in df.groupby("parental level of education")]
anova = stats.f_oneway(*grupos)
print(f"ANOVA -> statistic={anova.statistic:.2f}, p-value={anova.pvalue:.4g}")
```

```
ANOVA -> statistic=6.52, p-value=5.592e-06
```

a) $H_0: \mu_1 = \mu_2 = \mu_3 = \mu_4 = \mu_5 = \mu_6$ (las medias de `math score` son iguales en los 6 niveles educativos). H_1 : al menos una de las medias es diferente de las demás.

b) $p\text{-value} = 5.59 \times 10^{-6} \ll \alpha (0.05) \rightarrow$ **se rechaza H_0** .

c) Porque "las medias son diferentes" sugiere que *todas* difieren entre sí. H_1 solo afirma que existe *al menos una* diferencia — podrían ser 5 grupos casi idénticos y uno solo separado del resto, y H_1 seguiría siendo la conclusión correcta.

Ejercicio 3 — Programar la regla de decisión

```
def decidir(p_value, alpha=0.05):
    if p_value < alpha:
        return "se rechaza H0"
    else:
        return "no se rechaza H0"

p_ejemplo = 0.023
print(f"Con p-value = {p_ejemplo}: {decidir(p_ejemplo)}")
```

Con p-value = 0.023: se rechaza H_0

a) "se rechaza H_0 " ($0.023 < 0.05$).

b) "Hay evidencia estadísticamente significativa de que existe una diferencia entre los grupos."

c) Confundirías $P(\text{datos} \mid H_0)$ con $P(H_0 \mid \text{datos})$: el p-value es la probabilidad de los datos **asumiendo que H_0 es cierta**, no la probabilidad de que H_0 sea cierta dados los datos. Son cantidades distintas — el mismo error lógico que confundir "la probabilidad de toser si tienes gripa" con "la probabilidad de tener gripa si toses".

Ejercicio 4 — Elegir la prueba a partir de los supuestos

```
# Parte 1: caso hipotético
p_shapiro_A, p_shapiro_B, p_levene = 0.002, 0.41, 0.03
print("Normalidad A:", "se cumple" if p_shapiro_A >= alpha else "NO se cumple")
print("Normalidad B:", "se cumple" if p_shapiro_B >= alpha else "NO se cumple")
print("Homogeneidad:", "se cumple" if p_levene >= alpha else "NO se cumple")

# Parte 2: datos reales (math score por gender)
hombres = df.loc[df["gender"] == "male", "math score"]
mujeres = df.loc[df["gender"] == "female", "math score"]

sh_hombres = stats.shapiro(hombres)
sh_mujeres = stats.shapiro(mujeres)
lev = stats.levene(hombres, mujeres)

print(f"Shapiro hombres p={sh_hombres.pvalue:.4g}, Shapiro mujeres p={sh_mujeres.pvalue:.4g}, Levene p={lev.pvalue:.4g}")
```

Normalidad A: NO se cumple
Normalidad B: se cumple
Homogeneidad: NO se cumple

Shapiro hombres p=0.03802, Shapiro mujeres p=0.003510, Levene p=0.5563

- a)** En el caso hipotético, con normalidad y homogeneidad fallando, corresponde **Mann-Whitney U** (o la **prueba t de Welch**, que no exige varianzas iguales, si se prefiere una paramétrica).
- b)** En los datos reales: **ninguno de los dos grupos es normal** (ambos $p < 0.05$), pero **sí se cumple la homogeneidad de varianzas** ($p = 0.556 \geq 0.05$).
- c)** No coincide del todo: en el caso hipotético fallaban *ambos* supuestos; en los datos reales solo falla la normalidad, no la homogeneidad. Esto ilustra por qué siempre hay que revisar los dos supuestos por separado en cada análisis real, en vez de asumir un patrón fijo.
-

Ejercicio 5 — Aplicar los pasos 6 y 7 con datos reales

```
standard = df.loc[df["lunch"] == "standard", "writing score"]
reducido = df.loc[df["lunch"] == "free/reduced", "writing score"]

print(f"\n standard = {len(standard)}, media = {standard.mean():.2f}")
print(f"\n free/reduced = {len(reducido)}, media = {reducido.mean():.2f}")

levene_lunch = stats.levene(standard, reducido)
t_lunch = stats.ttest_ind(standard, reducido)
u_lunch = stats.mannwhitneyu(standard, reducido, alternative="two-sided")

print(f"Levene -> p-value={levene_lunch.pvalue:.4g}")
print(f"t de Student -> t={t_lunch.statistic:.4f}, p-value={t_lunch.pvalue:.4g}")
print(f"Mann-Whitney U -> p-value={u_lunch.pvalue:.4g}")
print(f"Decisión: {decidir(t_lunch.pvalue)}")
```

```
n standard = 645, media = 70.82
n free/reduced = 355, media = 63.02
Levene -> p-value=0.1051
t de Student -> t=8.0098, p-value=3.186e-15
Mann-Whitney U -> p-value=5.081e-14
Decisión: se rechaza H0
```

Interpretación: hay evidencia estadísticamente muy fuerte de que el puntaje de escritura difiere según el tipo de almuerzo: los estudiantes con almuerzo `standard` promedian cerca de 7.8 puntos más que los de `free/reduced`. Al ser datos observacionales, esto es una asociación — probablemente refleja diferencias socioeconómicas de fondo — y no prueba que el tipo de almuerzo *cause* directamente el puntaje.

Ejercicio 6 — Detectar el error en una interpretación (con datos reales)

```
none = df.loc[df["test preparation course"] == "none", "math score"]
completado = df.loc[df["test preparation course"] == "completed", "math score"]
p_curso = stats.mannwhitneyu(none, completado, alternative="two-sided").pvalue

interpretacion_incorrecta = (
    f"Obtuve un p-value de {p_curso:.2g}, así que estoy "
    f"{(1 - p_curso) * 100:.1f}% seguro de que el curso causa la mejora en la nota."
)
interpretacion_correcta = (
    f"Obtuve un p-value de {p_curso:.2g} (menor que  $\alpha$  = {alpha}), lo que es evidencia "
    "estadísticamente significativa de que el curso está asociado con una mejor nota – "
    "aunque, al ser datos observacionales, no puedo afirmar que el curso sea la causa."
)

print(interpretacion_incorrecta)
print(interpretacion_correcta)
```

Obtuve un p-value de 8e-08, así que estoy 100.0% seguro de que el curso causa la mejora en la nota.
Obtuve un p-value de 8e-08 (menor que α = 0.05), lo que es evidencia estadísticamente significativa de que el curso está asociado con una mejor nota – aunque, al ser datos observacionales, no puedo afirmar que el curso sea la causa.

Respuesta: Python calcula `(1 - p_curso) * 100 = 100.0%` sin ningún error de sintaxis — pero ese número no tiene ningún significado estadístico. `1 - p-value` **no** es la "confianza en H1"; el p-value nunca se resta de 1 para obtener una probabilidad de la hipótesis.

Además, incluso si la operación fuera válida, un p-value bajo no prueba causalidad (Error 2 del `.md`): son datos observacionales, no un experimento aleatorizado. Esta salida "100.0% seguro" es exactamente el tipo de frase engañosa que el código puede producir perfectamente bien mientras el razonamiento detrás está equivocado — de ahí la importancia de entender la estadística, no solo saber ejecutar `scipy.stats`.

Ejercicio 7 — Significancia vs. tamaño del efecto (simulado)

```
estudios = {
    "Estudio A": {"n": 30, "diferencia": 8, "p": 0.09},
    "Estudio B": {"n": 5000, "diferencia": 0.3, "p": 0.001},
}
for nombre, datos in estudios.items():
    print(f"{nombre}: n={datos['n']}, diferencia={datos['diferencia']} puntos -> {decidir(datos['p'])}")
```

```
Estudio A: n=30, diferencia=8 puntos -> no se rechaza H0
Estudio B: n=5000, diferencia=0.3 puntos -> se rechaza H0
```

Respuesta: se rechaza H_0 solo en el **Estudio B**. Sin embargo, la diferencia del **Estudio A (8 puntos)** es probablemente más relevante en la práctica que la del Estudio B (apenas 0.3 puntos). Con una muestra enorme ($n = 5000$), hasta una diferencia mínima se vuelve "estadísticamente significativa" — el tamaño de muestra puede hacer significativo un efecto irrelevante, o dejar sin detectar (por falta de poder estadístico) un efecto grande pero real, como en el Estudio A.

Ejercicio 8 — Errores tipo I y II en un caso médico

```
def evaluar_decision(situacion_real, decision_estudio):  
    if decision_estudio == situacion_real:  
        return "Decisión correcta"  
    elif decision_estudio == "el tratamiento SÍ reduce la presión" and situacion_real == "no hay diferencia":  
        return "Error tipo I: se adopta un tratamiento que no funciona"  
    else:  
        return "Error tipo II: se descarta un tratamiento que sí funciona"  
  
print(evaluar_decision("no hay diferencia", "el tratamiento SÍ reduce la presión"))  
print(evaluar_decision("el tratamiento SÍ reduce la presión", "no hay diferencia"))
```

```
Error tipo I: se adopta un tratamiento que no funciona  
Error tipo II: se descarta un tratamiento que sí funciona
```

a) Error tipo I: rechazar H_0 cuando en realidad es verdadera — concluir que el tratamiento nuevo funciona mejor cuando en realidad no hace ninguna diferencia. Consecuencia: se adopta un tratamiento sin beneficio real, con sus costos y posibles efectos secundarios innecesarios.

b) Error tipo II: no rechazar H_0 cuando en realidad es falsa — concluir que no hay diferencia cuando el tratamiento sí es mejor. Consecuencia: se descarta un tratamiento realmente efectivo, privando a futuros pacientes de un beneficio real.

c) Respuesta abierta: en un contexto médico suele argumentarse que el error tipo II es más grave (negar un tratamiento que sí funciona), pero depende de los riesgos y costos del tratamiento — si tiene efectos secundarios severos, el error tipo I podría ser el más grave. Lo importante es justificar con el contexto, no memorizar cuál error es "siempre peor".

Material relacionado

Conceptos sin código: [02_Pruebas_Hipotesis_conceptos.md](#) . Versión estudiante de este taller:

[Taller_02_Prueba_Hipotesis_conceptos.md](#) . Presentación: [02_Prueba_Hipotesis_conceptos.pptx](#) . Taller de la semana anterior:

[Taller_01_Estadistica_inferencial_conceptos_profesor.md](#) .