

Taller: Prueba de Hipótesis (con Python)

Fundamentos para IA · NRC 94103 · Semana 6 Versión docente — solución completa, paso a paso, con código

Este *notebook* resuelve en detalle los 8 ejercicios de `Taller_03_Prueba_Hipotesis_conceptos_profesor.md`, que a su vez desarrollan con código los ejercicios conceptuales de `02_Pruebas_Hipotesis_conceptos.md`. Reutiliza (y reaplica a variables nuevas) las fórmulas ya derivadas en los talleres 01 y 02: Levene, prueba t, Mann-Whitney U y ANOVA.

Configuración inicial

```
In [1]: import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
from scipy import stats

sns.set_theme(style="whitegrid")
pd.set_option("display.max_columns", None)

df = pd.read_csv("StudentsPerformance.csv")
alpha = 0.05
print(f"Dataset: {df.shape[0]} estudiantes, {df.shape[1]} columnas.")

# --- Funciones reutilizables (fórmulas ya derivadas en los talleres 01 y 02) ---

def decidir(p_value, alpha=0.05):
    return "se rechaza H0" if p_value < alpha else "no se rechaza H0"

def levene_manual(g1, g2):
    Ns = [len(g1), len(g2)]
    N, k = sum(Ns), 2
    centros = [np.median(g1), np.median(g2)]
    Z = [np.abs(np.asarray(g) - c) for g, c in zip([g1, g2], centros)]
    Zbar_i = [z.mean() for z in Z]
```

```

Zbar = np.concatenate(Z).mean()
numerador = (N - k) * sum(n * (zi - Zbar) ** 2 for n, zi in zip(Ns, Zbar_i))
denominador = (k - 1) * sum(((z - zi) ** 2).sum() for z, zi in zip(Z, Zbar_i))
W = numerador / denominador
return W, stats.f.sf(W, k - 1, N - k)

def ttest_manual(g1, g2):
    n1, n2 = len(g1), len(g2)
    m1, m2 = np.mean(g1), np.mean(g2)
    s1, s2 = np.std(g1, ddof=1), np.std(g2, ddof=1)
    sp2 = ((n1 - 1) * s1**2 + (n2 - 1) * s2**2) / (n1 + n2 - 2)
    se = np.sqrt(sp2 * (1 / n1 + 1 / n2))
    t = (m1 - m2) / se
    dfree = n1 + n2 - 2
    p = 2 * stats.t.sf(abs(t), dfree)
    return t, dfree, p

def mannwhitney_manual(g1, g2):
    """U1: estadístico U del PRIMER grupo (misma convención que scipy.stats.mannwhitneyu),
    calculado a partir de la suma de rangos de g1 en la muestra combinada."""
    n1, n2 = len(g1), len(g2)
    todos = np.concatenate([np.asarray(g1), np.asarray(g2)])
    rangos = stats.rankdata(todos)
    R1 = rangos[:n1].sum()
    U1 = R1 - n1 * (n1 + 1) / 2
    mu_U = n1 * n2 / 2
    sigma_U = np.sqrt(n1 * n2 * (n1 + n2 + 1) / 12)
    z = (U1 - mu_U) / sigma_U
    p = 2 * stats.norm.sf(abs(z))
    return U1, z, p

def anova_manual(grupos):
    k = len(grupos)
    N = sum(len(g) for g in grupos)
    grand_mean = np.concatenate(grupos).mean()
    SSB = sum(len(g) * (np.mean(g) - grand_mean) ** 2 for g in grupos)
    SSW = sum(((np.asarray(g) - np.mean(g)) ** 2).sum() for g in grupos)
    dfB, dfW = k - 1, N - k
    F = (SSB / dfB) / (SSW / dfW)
    p = stats.f.sf(F, dfB, dfW)
    return F, p

```

```
print("Funciones auxiliares listas: decidir, levene_manual, ttest_manual, mannwhitney_manual, anova_manual")
```

Dataset: 1000 estudiantes, 8 columnas.

Funciones auxiliares listas: decidir, levene_manual, ttest_manual, mannwhitney_manual, anova_manual

Ejercicio 1 — ¿Es candidata para una prueba de hipótesis?

Tres situaciones: (A) comparar `math score` entre géneros, (B) contar estudiantes por `lunch`, (C) correlación `reading` / `writing`.

```
In [2]: print("Situación B (conteo, descriptiva):")
        print(df["lunch"].value_counts())

        print("\nSituación A (comparación entre grupos):")
        print(df.groupby("gender")["math score"].mean().round(2))

        correlacion = df["reading score"].corr(df["writing score"])
        print(f"\nSituación C (relación entre variables): r = {correlacion:.3f}")
```

Situación B (conteo, descriptiva):

```
lunch
standard      645
free/reduced   355
Name: count, dtype: int64
```

Situación A (comparación entre grupos):

```
gender
female    63.63
male      68.73
Name: math score, dtype: float64
```

Situación C (relación entre variables): $r = 0.955$

a) Situación A (math score por gender): **sí es candidata** — hay comparación entre grupos y una pregunta de generalización hacia la población.

Situación B (conteo de `lunch`): **no es candidata** — `value_counts()` es pura estadística descriptiva.

Situación C (correlación reading/writing = 0.955): **sí es candidata** — mismo salto de "lo que veo en la muestra" a "lo que sería cierto en la población", aunque sea una relación y no una diferencia de grupos.

Ejercicio 2 — H0 y H1 con más de dos grupos (ANOVA paso a paso)

Situación: `math score` según los 6 niveles de `parental level of education`.

$$F = \frac{MS_B}{MS_W} = \frac{SS_B/(k-1)}{SS_W/(N-k)}$$

```
In [3]: grupos_edu = [g["math score"].values for _, g in df.groupby("parental level of education")]

F_manual, p_manual = anova_manual(grupos_edu)
print(f"ANOVA manual -> F={F_manual:.4f}, p-value={p_manual:.4g}")

anova_scipy = stats.f_oneway(*grupos_edu)
print(f"ANOVA (scipy) -> F={anova_scipy.statistic:.4f}, p-value={anova_scipy.pvalue:.4g}")
print(f"\nDecisión: {decidir(anova_scipy.pvalue)}")
```

```
ANOVA manual -> F=6.5216, p-value=5.592e-06
ANOVA (scipy) -> F=6.5216, p-value=5.592e-06
```

Decisión: se rechaza H0

a) H0: $\mu_1=\mu_2=\mu_3=\mu_4=\mu_5=\mu_6$ (las 6 medias son iguales). H1: al menos una difiere.

b) $p\text{-value} \approx 5.59 \times 10^{-6} \ll \alpha \rightarrow$ **se rechaza H0.**

c) "Las medias son diferentes" implicaría que *todas* difieren; H1 solo exige que exista *al menos una* diferencia — podrían ser 5 grupos casi idénticos y uno solo distinto, y H1 seguiría siendo correcta.

Ejercicio 3 — Programar la regla de decisión

La función `decidir()` (ya definida arriba) automatiza la comparación p-value vs. α .

```
In [4]: p_ejemplo = 0.023
print(f"Con p-value = {p_ejemplo}: {decidir(p_ejemplo)}")
```

Con p-value = 0.023: se rechaza H_0

a) "se rechaza H_0 " ($0.023 < 0.05$).

b) "Hay evidencia estadísticamente significativa de que existe una diferencia entre los grupos."

c) Confundirías $P(\text{datos} \mid H_0)$ —lo que sí mide el p-value— con $P(H_0 \mid \text{datos})$ —lo que **no** mide—. Es el mismo tipo de error que confundir "la probabilidad de toser si tienes gripa" con "la probabilidad de tener gripa si toses": son preguntas relacionadas, pero no intercambiables.

Ejercicio 4 — Elegir la prueba a partir de los supuestos

Parte 1: caso hipotético del documento. **Parte 2:** los mismos supuestos, pero con datos reales (`math score` por `gender`).

```
In [5]: # Parte 1: caso hipotético
p_shapiro_A, p_shapiro_B, p_levene_hip = 0.002, 0.41, 0.03
print("--- Caso hipotético ---")
print("Normalidad A:", "se cumple" if p_shapiro_A >= alpha else "NO se cumple")
print("Normalidad B:", "se cumple" if p_shapiro_B >= alpha else "NO se cumple")
print("Homogeneidad:", "se cumple" if p_levene_hip >= alpha else "NO se cumple")

# Parte 2: datos reales
hombres = df.loc[df["gender"] == "male", "math score"]
mujeres = df.loc[df["gender"] == "female", "math score"]

sh_hombres = stats.shapiro(hombres)
sh_mujeres = stats.shapiro(mujeres)
W_lev, p_lev_manual = levene_manual(hombres, mujeres)
lev_scipy = stats.levene(hombres, mujeres)

print("\n--- Datos reales (math score por gender) ---")
```

```
print(f"Shapiro hombres p={sh_hombres.pvalue:.4g}, Shapiro mujeres p={sh_mujeres.pvalue:.4g}")
print(f"Levene manual -> W={W_lev:.6f}, p-value={p_lev_manual:.6f}")
print(f"Levene (scipy) -> W={lev_scipy.statistic:.6f}, p-value={lev_scipy.pvalue:.6f}")
```

--- Caso hipotético ---

Normalidad A: NO se cumple

Normalidad B: se cumple

Homogeneidad: NO se cumple

--- Datos reales (math score por gender) ---

Shapiro hombres p=0.03802, Shapiro mujeres p=0.00351

Levene manual -> W=0.346369, p-value=0.556309

Levene (scipy) -> W=0.346369, p-value=0.556309

a) Caso hipotético: normalidad y homogeneidad fallan ambas → **Mann-Whitney U** (o **t de Welch** si se prefiere paramétrica).

b) Datos reales: **ninguno de los dos grupos es normal**, pero **sí hay homogeneidad de varianzas** ($p=0.556 \geq 0.05$).

c) No coincide del todo: en el caso hipotético fallaban *ambos* supuestos; en los datos reales solo falla la normalidad. Por eso siempre hay que revisar los dos supuestos por separado en cada análisis real, en vez de asumir un patrón fijo.

Ejercicio 5 — Aplicar los pasos 6 y 7 con datos reales (las 3 pruebas, lado a lado)

Situación: `writing score` según `lunch`. Aquí se aplican **las tres fórmulas manuales** (Levene, t, Mann-Whitney) a esta nueva combinación de variables, para comparar directamente con `scipy`.

```
In [6]: standard = df.loc[df["lunch"] == "standard", "writing score"]
reducido = df.loc[df["lunch"] == "free/reduced", "writing score"]

print(f"\n standard = {len(standard)}, media = {standard.mean():.2f}")
print(f"\n free/reduced = {len(reducido)}, media = {reducido.mean():.2f}")

# Levene
W_lev5, p_lev5_manual = levene_manual(standard, reducido)
lev5_scipy = stats.levene(standard, reducido)
print(f"\nLevene manual -> p={p_lev5_manual:.4g} | scipy -> p={lev5_scipy.pvalue:.4g}")
```

```
# t de Student
t5_manual, df5_manual, p5_t_manual = ttest_manual(standard, reducido)
t5_scipy = stats.ttest_ind(standard, reducido)
print(f"t manual -> t={t5_manual:.4f}, p={p5_t_manual:.4g} | scipy -> t={t5_scipy.statistic:.4f}, p={t5_scipy.pvalue:.4g}")

# Mann-Whitney U
U5_manual, z5_manual, p5_u_manual = mannwhitney_manual(standard, reducido)
u5_scipy = stats.mannwhitneyu(standard, reducido, alternative="two-sided")
print(f"U manual -> U={U5_manual:.1f}, p~{p5_u_manual:.4g} | scipy -> U={u5_scipy.statistic:.1f}, p={u5_scipy.pvalue:.4g}")

print(f"\nDecisión (con la prueba t): {decidir(t5_scipy.pvalue)}")
```

```
n standard = 645, media = 70.82
n free/reduced = 355, media = 63.02
```

```
Levene manual -> p=0.1051 | scipy -> p=0.1051
t manual -> t=8.0098, p=3.186e-15 | scipy -> t=8.0098, p=3.186e-15
U manual -> U=147389.0, p~5.142e-14 | scipy -> U=147389.0, p=5.081e-14
```

Decisión (con la prueba t): se rechaza H_0

Interpretación: las tres pruebas coinciden en rechazar H_0 . Hay evidencia estadísticamente muy fuerte de que el puntaje de escritura difiere según el tipo de almuerzo: `standard` promedia ≈ 7.8 puntos más que `free/reduced`. Al ser datos observacionales, esto es una **asociación** (probablemente refleja diferencias socioeconómicas de fondo), no una prueba de que el almuerzo *cause* directamente el puntaje.

Ejercicio 6 — Detectar el error en una interpretación (con datos reales)

```
In [7]: none = df.loc[df["test preparation course"] == "none", "math score"]
completado = df.loc[df["test preparation course"] == "completed", "math score"]
p_curso = stats.mannwhitneyu(none, completado, alternative="two-sided").pvalue

interpretacion_incorrecta = (
    f"Obtuve un p-value de {p_curso:.2g}, así que estoy "
    f"{(1 - p_curso) * 100:.1f}% seguro de que el curso causa la mejora en la nota."
)
interpretacion_correcta = (
```

```

f"Obtuve un p-value de {p_curso:.2g} (menor que  $\alpha = \{\alpha\}$ ), lo que es evidencia "
"estadísticamente significativa de que el curso está asociado con una mejor nota – "
"aunque, al ser datos observacionales, no puedo afirmar que el curso sea la causa."
)

print("INCORRECTA:", interpretacion_incorrecta)
print("\nCORRECTA: ", interpretacion_correcta)

```

INCORRECTA: Obtuve un p-value de 8e-08, así que estoy 100.0% seguro de que el curso causa la mejora en la nota.

CORRECTA: Obtuve un p-value de 8e-08 (menor que $\alpha = 0.05$), lo que es evidencia estadísticamente significativa de que el curso está asociado con una mejor nota – aunque, al ser datos observacionales, no puedo afirmar que el curso sea la causa.

Respuesta: Python calcula $(1 - p_curso) * 100 = 100.0\%$ sin ningún error de sintaxis — pero ese número no tiene significado estadístico. $1 - p\text{-value}$ **no** es "confianza en H1"; el p-value nunca se resta de 1 para volverse una probabilidad de la hipótesis. Además, un p-value bajo no prueba causalidad. El código puede ejecutar perfectamente una interpretación equivocada — de ahí la importancia de entender la estadística, no solo saber ejecutar `scipy.stats`.

Ejercicio 7 — Significancia vs. tamaño del efecto (simulado)

```

In [8]: estudios = {
    "Estudio A": {"n": 30, "diferencia": 8, "p": 0.09},
    "Estudio B": {"n": 5000, "diferencia": 0.3, "p": 0.001},
}
for nombre, datos in estudios.items():
    print(f"{nombre}: n={datos['n']}, diferencia={datos['diferencia']} puntos -> {decidir(datos['p'])}")

fig, ax1 = plt.subplots(figsize=(6, 4))
nombres = list(estudios.keys())
diferencias = [estudios[n]["diferencia"] for n in nombres]
pvals = [estudios[n]["p"] for n in nombres]

ax1.bar(nombres, diferencias, color=["#3D5A80", "#E07A5F"], alpha=0.8)
ax1.set_ylabel("Diferencia observada (puntos)")
for i, (d, p) in enumerate(zip(diferencias, pvals)):
    ax1.text(i, d + 0.2, f"p={p}", ha="center", fontweight="bold")
ax1.set_title("Diferencia práctica vs. p-value: no siempre van de la mano")


```



```
plt.tight_layout()
plt.show()
```

Estudio A: $n=30$, diferencia=8 puntos $\rightarrow$ no se rechaza H_0

Estudio B: $n=5000$, diferencia=0.3 puntos $\rightarrow$ se rechaza H_0



Respuesta: se rechaza H_0 solo en el **Estudio B**, pero la diferencia del **Estudio A (8 puntos)** es probablemente más relevante en la práctica que la del Estudio B (0.3 puntos). Con una muestra enorme ($n=5000$), hasta una diferencia mínima se vuelve "significativa" — el tamaño de muestra puede hacer significativo un efecto irrelevante, o dejar sin detectar uno grande pero real (como el Estudio A, que además tiene una muestra pequeña — recordar el Ejercicio 6 del Taller 02).

Ejercicio 8 — Errores tipo I y II en un caso médico

```
In [9]: def evaluar_decision(situacion_real, decision_estudio):
        if decision_estudio == situacion_real:
            return "Decisión correcta"
        elif decision_estudio == "el tratamiento SÍ reduce la presión" and situacion_real == "no hay diferencia":
            return "Error tipo I: se adopta un tratamiento que no funciona"
        else:
            return "Error tipo II: se descarta un tratamiento que sí funciona"

print(evaluar_decision("no hay diferencia", "el tratamiento SÍ reduce la presión"))
print(evaluar_decision("el tratamiento SÍ reduce la presión", "no hay diferencia"))
print(evaluar_decision("el tratamiento SÍ reduce la presión", "el tratamiento SÍ reduce la presión"))
```

Error tipo I: se adopta un tratamiento que no funciona

Error tipo II: se descarta un tratamiento que sí funciona

Decisión correcta

a) Error tipo I: rechazar H_0 siendo verdadera — adoptar un tratamiento que no funciona (costos y efectos secundarios innecesarios).

b) Error tipo II: no rechazar H_0 siendo falsa — descartar un tratamiento que sí funciona (se priva a futuros pacientes de un beneficio real).

c) Respuesta abierta: en medicina suele considerarse más grave el error tipo II, pero depende de los riesgos y costos del tratamiento — si tiene efectos secundarios severos, el error tipo I podría ser peor. Lo importante es justificar con el contexto.

Resumen: las 4 fórmulas reutilizadas en este taller

Función	Qué calcula	Usada en
levene_manual	Homogeneidad de varianzas	Ejercicios 4 y 5
ttest_manual	Diferencia de medias (paramétrica)	Ejercicio 5
mannwhitney_manual	Diferencia de medias (no paramétrica, por rangos)	Ejercicio 5
anova_manual	Diferencia de medias, 3+ grupos	Ejercicio 2

Material relacionado: versión conceptual sin código — `02_Pruebas_Hipotesis_conceptos.md` . Talleres previos:

`Taller_01_Estadistica_inferencial_profesor.ipynb` , `Taller_02_Estadistica_inferencial_conceptos_profesor.ipynb` .