

Taller de refuerzo — Regresión logística paso a paso

Fundamentos para IA · NRC 94103 · Semana 8 Estadística inferencial 3 regresión logística

Este taller afianza, en orden, los conceptos que evalúa "MA Evaluación 8" (ver también la clave de esa evaluación en 02_Evaluacion_8_clave_respuestas.md). Cada ejercicio corresponde uno a uno con el mismo número en 03_Evaluacion_explicacion_estudiante.md , que trae la versión sin resolver de estas mismas preguntas.

Caso guía y datos: StudentsPerformance.csv (1000 estudiantes), $Y = 1$ si el estudiante **aprueba matemáticas** ($\text{math score} \geq 60$), $X = \text{reading score}$. Modelo ajustado sobre los 1000 estudiantes:

$$b_0 = -10.2254 \quad b_1 = 0.16721$$

Paso 1. Del predictor lineal z a la probabilidad (sigmoide)

Concepto que refuerza: Preguntas 1 y 2 de la evaluación (el modelo es lineal en el *logit*, y la sigmoide convierte z en una probabilidad entre 0 y 1).

Paso A — predictor lineal: $z = b_0 + b_1 \cdot X$
Paso B — función sigmoide: $p(x) = 1 / (1 + e^{(-z)})$

Ejercicio 1.1 — Solución

reading score	$z = b_0 + b_1 \cdot X$	$p(x) = 1/(1+e^{-z})$
40	$-10.2254 + 0.16721 \cdot 40 = -3.537$	0.028 (2.8%)
60	$-10.2254 + 0.16721 \cdot 60 = -0.192$	0.452 (45.2%)
70	$-10.2254 + 0.16721 \cdot 70 = 1.480$	0.814 (81.4%)
90	$-10.2254 + 0.16721 \cdot 90 = 4.824$	0.992 (99.2%)

Lectura del resultado: a medida que `reading score` sube, z sube de forma **lineal** (siempre suma 0.167 por cada punto), pero $p(x)$ **no** sube en línea recta: crece rápido cerca de $z=0$ (alrededor de `reading score` = 61 , donde $p(x) \approx 0.5$) y se aplana en los extremos, cada vez más cerca de 0 o de 1. Esa forma de "S" es la curva sigmoide.

Ejercicio 1.2 — Solución

Verdadero, pero solo dentro de este modelo tan simple. Como el modelo usa una única variable (`reading score`), `z` y por lo tanto `p(x)` dependen únicamente de ese valor: mismo `x` $\rightarrow$ mismo `z` $\rightarrow$ mismo `p(x)` . Esto cambiaría si el modelo incluyera más variables (por ejemplo, `writing score` también): ahí dos estudiantes con el mismo `reading score` pero distinto `writing score` sí podrían tener probabilidades distintas.

Paso 2. Odds y odds ratio

Concepto que refuerza: Preguntas 3 y 4 de la evaluación (definición de *odds*, complemento de la probabilidad, e interpretación del coeficiente mediante el *odds ratio*).

`odds` = `p` / (`1` - `p`)

Ejercicio 2.1 — Solución

- `reading score` = 60 : `p` = 0.452 $\rightarrow$ `odds` = 0.452 / (1-0.452) = 0.452/0.548 $\approx$ 0.825 . Como es menor a 1, en ese punto es **más probable no aprobar que aprobar** (coherente con que `p` < 0.5).
- `reading score` = 70 : `p` = 0.814 $\rightarrow$ `odds` = 0.814 / (1-0.814) = 0.814/0.186 $\approx$ 4.38 . Los odds de aprobar son de casi **4.4 a 1** a favor de aprobar.

Ejercicio 2.2 — Solución

OR = $e^{0.16721} \approx 1.182$.

Significado: por cada punto adicional en `reading score` , los *odds* de aprobar matemáticas se multiplican por 1.182 (aumentan un 18.2%), manteniendo todo lo demás igual. Es un efecto **multiplicativo sobre los odds**, no una suma directa sobre la probabilidad — por eso el mismo aumento de un punto en `reading score` mueve más la probabilidad cerca del 50% que en los extremos (como se vio en el paso 1).

Comprobación con los odds del ejercicio 2.1: si subieras `reading score` de 60 a 61 (un punto), los nuevos odds deberían ser aproximadamente 0.825 * 1.182 $\approx$ 0.975 . Puede pedirse al estudiante que lo verifique calculando `z` y `p(x)` para `reading score` = 61 .

Paso 3. El umbral de decisión y sus consecuencias

Concepto que refuerza: Parte de la Pregunta 4 (el rol del umbral) y las tarjetas de precisión/recall del material de teoría.

Ejercicio 3.1 — Solución

reading score	p(x)	Clasificación (t=0.5)
40	0.028	No aprueba
60	0.452	No aprueba (queda justo por debajo de 0.5)

reading score	p(x)	Clasificación (t=0.5)
70	0.814	Aprueba
90	0.992	Aprueba

Ejercicio 3.2 — Solución

Con $t = 0.8$, el estudiante de $\text{reading score} = 70$ ($p = 0.814$) **sigue clasificado como "aprueba"**, porque 0.814 todavía supera 0.8 (por poco). En general, **subir el umbral reduce la cantidad de casos clasificados como positivos** (aprueba): el modelo se vuelve más exigente, exige más confianza antes de predecir el evento. Esto normalmente sube la **precisión** (los que sí marca como "aprueba" son casi siempre correctos) pero baja el **recall** (deja pasar como "no aprueba" a algunos que sí aprobaban, porque su probabilidad no alcanzó el nuevo umbral tan alto).

Paso 4. Evaluando el modelo: matriz de confusión

Concepto que refuerza: las tarjetas de "Precisión, Recall y umbral" de la teoría, y la idea de que *accuracy* puede engañar con clases desbalanceadas.

	Predicho: no aprueba	Predicho: aprueba
Real: no aprueba	227 (VN)	96 (FP)
Real: aprueba	72 (FN)	605 (VP)

Ejercicio 4.1 — Solución

a) $\text{accuracy} = (605 + 227) / 1000 = 832/1000 = 0.832 \rightarrow \mathbf{83.2\%}$

b) $\text{precisión} = 605 / (605 + 96) = 605/701 \approx 0.863 \rightarrow \mathbf{86.3\%}$ (de los que el modelo dice que aprueban, 86.3% aprueba de verdad)

c) $\text{recall} = 605 / (605 + 72) = 605/677 \approx 0.894 \rightarrow \mathbf{89.4\%}$ (de los que sí aprueban, el modelo detecta al 89.4%)

Ejercicio 4.2 — Solución

Un modelo "tonto" que siempre predice "aprueba" acertaría en los 677 que sí aprueban y fallaría en los 323 que no aprueban: $\text{accuracy} = 677/1000 = 0.677 \rightarrow \mathbf{67.7\%}$, sin haber aprendido absolutamente nada. Esto ilustra por qué la *accuracy* sola puede engañar: un número alto (67.7%) no significa que el modelo sea bueno, solo refleja que una clase es mucho más frecuente que la otra. Por eso conviene mirar también precisión y recall (y, cuando hace falta, comparar contra ese "modelo tonto" como línea base).

Paso 5. Estadística inferencial: ¿el efecto es real o es azar?

Concepto que refuerza: Pregunta 5 de la evaluación (distinguir el modelado de la validación estadística: inferencia, confianza, significancia, colinealidad).

- **H0 (hipótesis nula):** el verdadero coeficiente de `reading score` es cero (no influye).
- **H1 (hipótesis alternativa):** el verdadero coeficiente es distinto de cero (sí influye).
- Prueba de Wald: $z \approx 15.3$, $p\text{-value} \approx 0 \rightarrow$ se **rechaza H0** con alta significancia y confianza.

Ejercicio 5.1 — Solución

Modelado	Validación estadística
sigmoide	p-value
odds ratio	intervalo de confianza
umbral	colinealidad
z (predictor lineal)	

Por qué: sigmoide, odds ratio, umbral y `z` son piezas de **cómo el modelo calcula y comunica una predicción**. p-value, intervalo de confianza y colinealidad son herramientas para **auditar si ese modelo es confiable**: si el efecto de una variable es real (p-value, confianza) o si hay un problema que dificulta confiar en los coeficientes (colinealidad, cuando dos variables predictoras están muy correlacionadas entre sí y el modelo no puede distinguir bien el aporte de cada una).

Ejercicio 5.2 — Solución

No es correcto. Un p-value bajo dice que el efecto de `reading score` es **estadísticamente significativo** (muy probablemente real, no azar), pero no dice nada sobre qué tan **completo** es el modelo. De hecho, en el Paso 4 el modelo se equivoca en 168 de 1000 estudiantes (96 falsos positivos + 72 falsos negativos), es decir, acierta el 83.2%, no el 100%. Significancia estadística (¿el efecto es real?) y capacidad predictiva completa (¿el modelo acierta siempre?) son dos preguntas distintas — un punto útil para resaltar en clase, porque es un error de interpretación muy común.

Autoevaluación final (mímica de la evaluación real) — Claves de comprobación

1. Porque la combinación lineal $b_0 + b_1 \cdot x$ predice directamente el logit $\log(p/(1-p))$, no p ; p se obtiene después con la sigmoide, y esa relación no es una línea recta.
2. $p(x) = 1/(1+e^{-z})$: z es el predictor lineal (combinación de variables con sus coeficientes), e es la constante de Euler (~ 2.718), y $p(x)$ es la probabilidad resultante, siempre entre 0 y 1.
3. *Odds* = probabilidad de que ocurra el evento sobre la probabilidad de que no ocurra. Con $p=0.75$: $\text{odds} = 0.75/0.25 = 3$ (3 a 1 a favor del evento).
4. El odds ratio mide cuánto se multiplican los *odds* del evento por cada unidad que sube una variable. Un $OR = 2$ significa que los odds se **duplican** por cada unidad adicional de esa variable.
5. Modelado: la sigmoide, el umbral, el predictor lineal z . Validación estadística: el p-value de un coeficiente, el intervalo de confianza, la colinealidad entre predictoras. (Cualquier ejemplo coherente del estudiante, distinto al del

taller, es válido.)

Notas para la clase

- Los pasos 1 y 2 suelen ser los más difíciles de interiorizar: insistir en que **el modelo nunca predice la probabilidad directamente**, siempre pasa primero por z (combinación lineal) y luego por la sigmoide.
- El ejercicio 4.2 (modelo "tonto" al 67.7%) es un buen momento para preguntar en voz alta "¿es bueno un 83.2% de exactitud aquí?" — la respuesta correcta es "mejor que el tonto, pero hay que compararlo siempre contra esa línea base, no contra un número aislado".
- El ejercicio 5.2 conecta directamente con un error de interpretación frecuente en evaluaciones anteriores: confundir significancia estadística con exactitud predictiva. Vale la pena remarcarlo antes del examen.